

Tarea- Mapas auto-organizables

Oscar Andrés Rosas Hernández - Redes Neuronales.

Universidad Nacional Autónoma de México, Facultad de Ciencias

I. MAPAS DE KOHOMEN EN LA VIDA REAL (ARTÍCULO)

Veamos una aplicación (artículo) para los SOMs (ej. Kohonen) en el mundo real, que están dando una solución a un problema específico y veamos cual es la idea general para dar una solución al problema planteado.

Este será: **Picking Mutual Funds with Self-Organizing Maps** by Guido Deboeck [1]

I-A. La idea

La idea es usar mapas auto organizados (en su versión original en la que tenemos un vector en una sola dimensión) que nos permitan traducir datos multidimensionales de fondos mutuos (mutual funds) en simples mapas de dos dimensiones.

Estos mapas proporcionan una mejora significativa sobre la información que tradicionalmente se publica en los fondos de inversión. Crean una mejor base para la selección de una cartera, para la comparación de el desempeño de los fondos mutuos y para la creación de puntos de referencia.

Para esto usaron datos publicados por Morningstar, utilizaron los mapas auto organizados para demostrar claramente distinciones y patrones entre los fondos mutuos mejor calificados.

Como entradas usamos el rendimiento de los fondos mutuos, las mediciones de riesgo de Morningstar, la “tenencia” de los gestores de inversiones, y las diversas relaciones de gastos.

Con este trabajo se puede ver que los SOM simplifican clasificación de fondos; pueden usarse para el apoyo en la toma de decisiones; y para proporcionar clasificaciones que tienen más significado que simples las listas ordenadas basadas en múltiples criterios pues no necesitan hacer presuposiciones.

Estos mapas se utiliza para buscar patrones entre fondos mutuos aparentemente similares. La principal razon para usar SOM son:

- Es un método de minería de datos numérico en lugar de simbólico
- Es un método no paramétrico, lo que significa que no hay suposiciones a priori sobre como debe hacerse la distribución de los datos.
- Es un método que puede detectar estructuras o patrones inesperados mediante el aprendizaje sin supervisión.

I-B. El dataset

Morningstar es una empresa privada fundada en 1984 para proporcionar a los inversores información útil para tomar decisiones de inversión inteligentes e informadas.

42 Guido Deboeck

Table 3.1. Sample binary data matrix of selected mutual funds

[illegible]

Source: MorningStar Year-end Wrap January 1997

Figura 1. Figura 3.1: [1]

Morningstar publica Morningstar Mutual Funds, una revista analítica exhaustiva sobre fondos mutuos “Morningstar Investor”, este es un compendio mensual de 450 fondos abiertos y 50 fondos cerrados seleccionados de un universo de más de 6000 fondos mutuos.

Los 500 representan, según Morningstar, los fondos más exitosos en la industria de fondos mutuos en la actualidad.

Como pueden ver se trata de un dataset binario y que tiene 20 características.

I-C. Arquitectura; fases de entrenamiento y clasificación

SOM de una matriz de datos de una muestra binaria, se utilizo un tamaño de mapa de 10 por 1, donde la longitud inicial del entrenamiento fue de 1000 epochs.

La tasa de aprendizaje inicial fue de 0.05 con un radio inicial de 5;

La segunda fase del entrenamiento fue de 10,000 epochs, con una tasa de aprendizaje de 0.02 y un radio de 1.

Todos los pesos fueron inicializados con un número aleatorio al inicio y se uso la clásica distancia euleriana.




Figura 2. Figura 3.3: [1]

Table 3.2. Key to mutual fund names and symbols

<i>Fund name</i>	<i>Symbol</i>	<i>Fund name</i>	<i>Symbol</i>
Harbor International	HBI	Templeton Global Small Companies	TGS
T. Row Price International	TRP	Templeton Growth	TGI
Scudder International	SCI	Merrill Lynch Dev Cap	MLD
Templeton Foreign	TFO	Templeton Developing Markets	TDM
Vanguard International Growth	VIG	Emerging Mkts Telecommunications	EMT
Fidelity World	FWO	Latin Am Equity	LAC
Janus World	JWO	Morgan Stanley Africa	AFR
Putham Growth	PUG	Morgan Stanley Emerg Mkts	MSE
Scudder Global	SCG	Templeton Emerging Markets	TEM

Figura 3. Figura 3.2: [1]

I-D. Resultados

El primer ejemplo en el artículo es un SOM de 1 por 10 neuronas. La figura 3.1 muestra que varios fondos de inversión se agrupan.

Por ejemplo, Fidelity World (FWO), Janus World (JWO), Scudder Global (SCG) y Templeton Global Small Companies (TGS) se agrupan en una neurona;

Las telecomunicaciones de mercados emergentes (EMT), la renta variable de América Latina (LAC), Morgan Stanley África (AFR) y los mercados emergentes de Morgan Stanley (MSE) se agrupan en otra neurona.

Hay otras tres neuronas que contienen dos fondos mutuos.

Dado que los vectores de entrada que son similares se agrupan en las mismas neuronas o en las cercanas, las agrupaciones que se muestran en la Figura 3.1 indican la similitud de los atributos de entrada entre los fondos que están en las mismas neuronas o en las cercanas.

Para verificar esto, busquemos en la Tabla 3.1 el primer grupo listado y lo comparamos con el segundo grupo principal.

El primer grupo de fondos está más diversificado, mientras que el segundo grupo contiene fondos que están más enfocados en sectores específicos o regiones geográficas del mundo. EMT, por ejemplo, es un fondo que solo invierte en empresas de telecomunicaciones; ALC, AFR y MSE son fondos que se especializan en inversiones en América Latina, África o mercados emergentes, respectivamente.

El sombreado gris de las neuronas en este mapa indica que esas neuronas con sombreado similar contienen fondos mutuos que están más cercanos entre sí, mientras que las neuronas que están sombreadas de manera oscura crean brechas entre los grupos.

II. IDEAS PARA USAR MAPAS DE KOHOMEN EN LA VIDA REAL

II-A. *Mi idea, arquitectura y demás*

Mi idea era desarrollar un mapa que le permitiera a un robot aprender como estaban relacionados los movimientos de los que era capaz, por ejemplo supongamos que tenemos un robot con 5 o 6 grados de libertad, en ese caso podemos usar un mapa autorganizado para poder visualizar de manera sencilla que patrones existen dentro de los movimientos que realiza el robot, investigando un poco mas me encuentre con que ya existe estas ideas, asi que ahora no puedo decir que es mi día porque me vi influido por otros, en especial por una red desarrollada por Saxon y Mukerjee que aprende el mapa de movimiento de un brazo robotico de dos grados de libertad utilizando un mapa de características autoorganizadas.

Este mapa se puede utilizar para planificar una ruta con el fin de evitar obstáculos. El sistema utiliza un mapa de características en 2D del como las propuestas por Kohonen.

La idea seria tener un mapa que recibe cuatro entradas: dos que representan la posición en el espacio cartesiano del efector final y dos que representan la posición del espacio articular (angulos) del efector final.

El sistema se entrena moviendo el brazo a un punto aleatorio en el espacio articular, y con esto registrando la posición cartesiana del efector final y luego alimentando la información cartesiana y articular a la red.

Después de muchos miles, y miles de estos movimientos, el sistema debería aprender un mapeo topológico del espacio de entrada.

En esencia, cada neurona representa un punto en el espacio cartesiano y un punto en el espacio articular. Una vez que se hubiera aprendido el mapa de movimiento, entonces tenemos la base para un medio bastante elegante de planificar trayectorias alrededor de obstáculos como lo describen Saxon y Mukerjee. La idea básica es que cada neurona en la red 2-D corresponde tanto a un espacio articular como a una posición de espacio cartesiano.

Por lo tanto realizar la planificación de la trayectoria utilizando esta red permite la incorporación de información tanto de espacios articulares como cartesianos, mientras que solo requiere que se busque una matriz 2D de posibles caminos. (lo cual puede potencialmente mejorar en gran medida la complejidad algorítmica de tiempo en la búsqueda).

Se pueden incorporar obstáculos desactivando las entradas del espacio articular a la red, aplicando la posición del espacio cartesiano de los objetos a la red y luego desactivando las neuronas que produjeron respuestas máximas.

Luego, se puede determinar una posible trayectoria que evite estos obstáculos eligiendo un camino a través de la matriz neural 2-D que comienza en la neurona que representa más parecido a la posición actual del espacio articular del brazo, evitando las neuronas que se han desactivado y terminando en

el punto que representa la posición más cercana a la posición deseada del efector final (en espacio articular o cartesiano).

Dadas las características de este problema podríamos sin ningún problema empezar en pesos aleatorios y usar la clásica distancia euleriana pues justo estamos hablando de problemas en lo que estamos mapeando al mundo real, por lo que resulta una forma de medir distancias bastante prometedora a priori.

II-B. ¿Porque es diferente a las demas redes?

Esta red es claramente diferente a todas las demas que hemos visto a lo largo del curso primeramente porque se trata de aprendizaje no supervisado, por lo que a finalidad es tomar un monton de datos y usar estos mapa para poder extraer características de la informacion.

En otras palabras: Los Mapas autorganizados de Kohonen son un tipo de red neuronal utilizado en problemas de reconocimiento de patrones.

Es especialmente capaz de agrupar y visualizar datos complejos de altas dimensiones y puede aplicarse potencialmente para resolver muchos problemas complejos del mundo real.

Si bien podemos argumentar que por ejemplo las redes convolucionales tambien son redes en las que ellas mismas aprenden los patrones necesarios para reconocer clases, esto es diferente y es justo en lo que acabo de decir, pues en el caso de las convolucionales ya tenemos unas clases dadas mientras que con estas podemos generar clases automaticamente.

Ahora el problema que acabamos de ver seria bastante dificil que hacer usando una red neuronal como las anteriores, de mismo modo que la idea que acabo de contar, pues por ejemplo para el brazo robotico tendriamos que darle a una red neuronal la relacion (y encontrar una forma de cuantificar la relacion) que existe entre las dimensiones cartesianas y las de articulaciones, pero en que en mi ejemplo justo lo que no tenemos son dichas relaciones y usamos los mapas autorganizados para encontrarlas.

II-C. Desafios

Uno de los principales problemas a los que me podria enfrentar es que la gente me dijera que para sistemas bien definidos, como este caso, a menudo será mucho más rápido calcular una respuesta exacta en lugar de utilizar un mapa autorganizados para obtener una solución aproximada.

Esto es particularmente cierto cuando se emplea un procesador secuencial.

Tambien habria que ver que al ser aprendizaje no supervisado necesitamos grandes cantidades de datos, mismos que quizas podrian contener una gran cantidad de errores (sobretudo con el uso de sensores) y sin conocer la relacion per ser nos seria bastante dificil para nosotros saber si la informacion que le estamos ingresando a la red es 100 % correcta.

Tambien elegir correctamente el espacio de salida y el radio de “vecindad”.

III. ¿PORQUÉ LA TASA DE APRENDIZAJE BAJA?

La selección de un factor de ganancia adecuado (learning rate), parece ser un compromiso entre la tasa de aprendizaje y la precisión del aprendizaje.

Si se elige un factor de alta ganancia, el aprendizaje continuará rápidamente, pero la red cambiará constantemente con cada nuevo patrón de entrada y, por lo tanto, es posible que no se clasifique de manera uniforme todo el espacio de entrada.

Por otro lado, si eligimos un factor de baja ganancia, entonces el aprendizaje será muy lento pero eventualmente debería alcanzar un resultado muy preciso. Por lo tanto, el factor de ganancia generalmente se elige para ser inicialmente bastante grande (para asegurar un aprendizaje inicial rápido) y luego se reduce para aumentar la precisión del resultado final.

Kohonen ha demostrado que una red unidimensional de neuronas con una sola entrada formará un mapeo ordenado siempre que α sea menor que uno. Sin embargo, no está claro que esta prueba se escalara para los casos en que la entrada o la red fueran de mayor dimensionalidad.

En particular, es poco probable que se aplique para el caso donde la entrada tenía una dimensión mucho más alta que la red.

La decisión sobre qué tamaño de vecindario se debe ajustar también parece determinarse de una manera un tanto ad hoc.

IV. IDEAS BIOLÓGICAS

V. DESVENTAJAS DE ESTE TIPO DE RED

Otra desventaja además de toda las que ya hemos dicho antes es que el comportamiento de tales redes no está bien definido matemáticamente.

Esto significa que la selección de parámetros de red (como factores de ganancia y tamaños de vecindad) debe realizarse de una manera un tanto ad hoc.

En particular existe la preocupación de una falta de garantía de que una red, que tiene permitido adaptarse en el mundo real, siempre mantendrá un mapeo ordenado consistente.

VI. MEMES

REFERENCIAS

- [1] Deboeck, G. and Kohonen, T. (1998). Visual explorations in finance with self-organising maps. London: Springer. Pueden descargarlo de aquí: (<https://www.springer.com/gp/book/9783540762669>)
- [2] Guido J Deboeck Neural Network World, May 2000 Financial Applications of Self-Organizing Maps Pueden descargarlo de aquí: (<https://pdfs.semanticscholar.org/e46d/77829d20ef37762d16bacc5d91eb114e25e.pdf>)
- [3] Self-Organizing Map: ScienceDirect <https://www.sciencedirect.com/topics/engineering/self-organizing-map>